

# Projet Ingénieur

## Mesurer les Infrastructures Routières

**Equipe:**

BALAKRISHNAN Sylvain

BONNAIL Julie

Alcatel • Lucent



École d'ingénieurs

**Télécom Physique**

Université de **Strasbourg**

## Table des matières

Liste des figures	2
1 Introduction	3
2 Rappels R1 à R5	3
3 Preuve de Concept : Analyse des Données Augmentées	4
3.1 Introduction . . . . .	4
3.2 Analyse des Données . . . . .	4
3.2.1 Initial ax . . . . .	4
3.2.2 Inverted ax . . . . .	5
4 Intelligence Artificielle	5
4.1 CNN Multi-labels . . . . .	5
4.2 Localisation GPS des détériorations . . . . .	8
4.2.1 Liaison entre les Dégradations Détectées et les Données GPS . . . . .	8
5 Conclusion	9
Bibliographie	10

## Liste des figures

1	Axe ax initial (Zoomé) . . . . .	4
2	Axe ax inversé dans le temps (Zoomé) . . . . .	5
3	Evaluation de l'accuracy au cours des epoch pour le CNN binaire . . . . .	6
4	Evaluation de la loss au cours des epoch pour le CNN binaire . . . . .	6
5	Evaluation de l'accuracy au cours des epoch pour le nouveau CNN multiclasse . . . . .	7
6	Evaluation de la loss au cours des epoch pour le nouveau CNN multiclasse . . . . .	7
7	Modification arbitraire des données GPS (test) . . . . .	8
8	Visualisation des données GPS arbitraires sur la carte . . . . .	8

## 1 Introduction

Les infrastructures routières jouent un rôle essentiel dans la mobilité quotidienne et les déplacements ponctuels. Des millions de conducteurs empruntent les routes pour atteindre leur destination. La détérioration de ces routes a un impact majeur sur la sécurité, avec des conséquences potentielles telles que des changements brusques de direction ou la perte de contrôle du véhicule en raison de trous inattendus. Cette négligence des routes endommagées peut entraîner des dommages aux véhicules, augmentant ainsi les coûts d'entretien. À une échelle plus large, des routes détériorées ralentissent les transports, affectant les échanges économiques et nuisant à l'économie locale et nationale. De plus, l'état des routes peut influencer l'évaluation de la force militaire d'un pays, particulièrement lors d'urgences nécessitant un déploiement rapide des forces.

L'objectif de ce projet est de développer une solution basée sur l'IA afin de faciliter l'entretien des routes. En formant une IA à reconnaître les dégradations sur une route, les cantonniers pourraient plus facilement entretenir les routes et ainsi améliorer la sécurité et l'expérience des usagers.

Dans cette étude, l'IA sera principalement entraînée sur les données d'accélération mesurées sur les véhicules. Pour fonctionner correctement, le modèle doit être capable de détecter diverses dégradations (bosses et obstacles, trous et fissures ainsi que graviers), quel que soit le type de véhicule d'où proviennent les données. Pour les besoins de l'étude, deux méthodes seront utilisées pour collecter les données d'accélération : une carte Arduino munie d'une *unité de mesure inertielle* (IMU) et un smartphone en utilisant l'accéléromètre contenu dans son dispositif.

Comme preuve de concept, une application pour smartphone sera créée et démontrera l'efficacité de cette méthode d'évaluation de la qualité des routes.

## 2 Rappels R1 à R5

Le projet a débuté par la collecte de données via Arduino et le développement d'une application Android, suivi de l'exploration des méthodes de classification de séquences, notamment l'utilisation d'un CNN. La réorganisation de l'équipe a entraîné des ajustements de calendrier. La revue n°5 a souligné le développement d'une nouvelle application Android intégrée à Google Drive pour simplifier l'utilisation des données.

La revue n°5 a introduit une approche de classification multi-classe avec un CNN utilisant une méthode de fenêtre glissante, montrant des résultats prometteurs pour des séquences plus courtes, mais identifiant des limitations pour les séquences plus longues. Cette dernière revue a également abordé les méthodes envisagées pour la validation des données augmentées, dans le but de confirmer leur intégrité.

Globalement, le projet a réalisé des avancées significatives sur le plan du développement d'applications et de l'exploration de la classification des séquences.

## 3 Preuve de Concept : Analyse des Données Augmentées

### 3.1 Introduction

La réalisation d'une preuve de concept (PoC) [2] est une importance cruciale dans le contexte de développement d'un modèle de détection de dégradations à partir de données accélérométriques. Cette démarche permet d'évaluer l'utilisabilité des données augmentées avant de pouvoir les déployer dans notre modèle de détection.

Elle permet d'expérimenter et de valider rapidement l'approche envisagée, en utilisant un ensemble initial de données limité. Cette étape préliminaire offre l'opportunité de détecter d'éventuels obstacles techniques, de régler des problèmes spécifiques et d'ajuster la méthodologie, garantissant ainsi une meilleure robustesse du modèle final.

Cette la réalisation d'une preuve de concept dans un projet de détection de dégradations à partir de données accélérométriques contribue à réduire les risques associés au déploiement d'une solution à grande échelle.

### Axes et Orientation

Le repère choisi pour les accélérations est défini comme suit :

- Positive X : Avant (Forward)
- Positive Y : Gauche (Left)
- Positive Z : Haut (Up)

### 3.2 Analyse des Données

Deux jeux de données sont examinés : Axe initial ax et Axe inversé ax (donnée augmentée). Tous deux concernent l'accélération selon l'axe des X. Chaque jeu de données est accompagné d'une interprétation. Nous allons nous intéresser plus particulièrement au cas où le robot a rencontré un dos d'âne.

#### 3.2.1 Initial ax




Figure 1: Axe ax initial (Zoomé)

**Interprétation :** Le robot accélère avant d'arriver au dos d'âne : les chocs des roues avant et arrière se distinguent par des pics importants de valeurs négatifs (ralentissements brutaux du robot). Nous remarquons également deux pics de valeurs positifs importants, qui indiquent que le robot réaccélère immédiatement

après. La fin de la séquence nous indique que le robot fini par conserver une vitesse stable après avoir passé l'obstacle.

### 3.2.2 Inverted ax

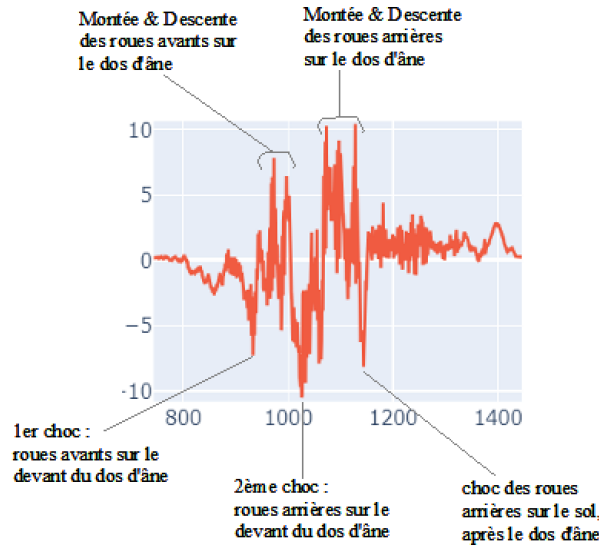


Figure 2: Axe ax inversé dans le temps (Zoomé)

**Interprétation :** Le robot semble dans ce cas présent décélérer avant d'arriver au dos d'âne : l'accélération devient négatif à l'approche du dos d'âne. Les chocs des roues avant et arrières se distinguent par des pics de valeurs négatifs (ralentissements brutaux du robot), mais sont moins importants que ceux du signal initial car le robot possède une vitesse moindre. Nous remarquons également deux pics de valeurs positifs importants, qui indiquent que le robot réaccélère dans sa traversée du dos d'âne. La moyenne positive d'environ 3km/h en fin de la séquence nous indique que le robot continue d'accélérer après avoir passer le dos d'âne, contrairement au signal initial.

### Conclusion

L'analyse des différentes configurations d'axes suggère que les données *ax inverted* sont valides pour le dataset. Cette conclusion est basée sur des variations dans le comportement du robot et des différences notables dans les intensités de choc pendant le passage des dos d'âne. Cette preuve de concept s'applique également aux autres opérations cohérentes sur les séquences afin d'obtenir des données augmentées.

## 4 Intelligence Artificielle

### 4.1 CNN Multi-labels

Pour déterminer les emplacements réels des dégradations sur la route, nous avons utilisé une méthode de fenêtre glissante sur les séquences accélérométriques [4]

Lors de la précédente revue, nous avons présenté une première version du modèle de fenêtre glissante pour la détection de multiples occurrences de dégradations au sein d'une même séquence. Cependant, cette approche s'est révélée imparfaite en raison d'une plage de détection non optimale, ne permettant pas de localiser précisément l'emplacement de la détection dans l'enregistrement. Pour remédier à cela, nous avons opté pour une nouvelle méthodologie en segmentant les différentes parties de la séquence. Dans un premier temps, nous avons mis en place un modèle de classification binaire visant à déterminer simplement la présence ou l'absence de dégradation. Cette démarche a nécessité la reconstruction de notre base de données.

Pour ce faire, nous avons développé un algorithme en langage Python qui a partitionné les données en fonction des valeurs de  $a_x$  et  $a_y$  représentant respectivement les composantes horizontales et verticales de l'accélération. Si la valeur  $\sqrt{a_x^2 + a_y^2}$  dépasse le seuil fixé à 1 (d'après l'étude des données) alors la séquence contient une dégradation, sinon ce n'est pas le cas. L'algorithme a ensuite organisé ces données en séquences de 300 lignes et a attribué des étiquettes (0 pour l'absence de dégradation, 1 pour la présence) à chacune. L'entraînement de ce modèle CNN binaire a produit des résultats très prometteurs, avec une précision de 99% et une perte (loss) de 0.01. La précision (accuracy) indique la proportion de prédictions correctes par rapport à l'ensemble des prédictions, tandis que la perte (loss) mesure la différence entre les valeurs prédites et les valeurs réelles. Voici les graphiques représentant l'accuracy et la loss au cours des epochs.




Figure 3: Evaluation de l'accuracy au cours des epoch pour le CNN binaire




Figure 4: Evaluation de la loss au cours des epoch pour le CNN binaire

Par la suite, la séquence étendue a été soumise au modèle en y ajoutant une fenêtre glissante de taille 300 et d'un pas de 50. Cette fenêtre glissante nous a fourni des informations sur les différentes plages où des dégradations étaient prédites. Un algorithme simple a ensuite permis de repérer les limites en triant les indices récupérés, en éliminant les doublons et en vérifiant leur séquence. Une fois les limites obtenues, la première séquence a été découpée en sous-séquences, et les différentes classes ont été prédites à l'aide de notre premier modèle CNN présenté précédemment.

Cependant, ce modèle initial, qui prédisait 7 classes à partir des données brutes enregistrées, a montré des résultats médiocres lorsqu'appliqué aux nouvelles données qui ne comprenaient que les dégradations, excluant les parties calmes utilisées lors de l'entraînement initial. Face à cette lacune, un nouveau modèle a été entraîné en excluant les parties calmes. Pour ce faire, chaque donnée initiale a été soumise à notre modèle de détection binaire de dégradation, et un nouveau script a permis de découper les nouvelles séquences en fonction des bornes détectées.

Cependant, le nouveau modèle de détection multiclasse n'a pas atteint la même performance que le modèle initial. Pour tenter d'améliorer ces résultats, nous avons repensé nos données d'entraînement. En effet les 7 classes à prédire étaient : "crack", "dos d'âne", "trou", "racine d'arbre", "pavé", "dos d'âne + trou" et "trou + crack + dos d'âne". Cependant, maintenant que l'on sépare chaque type de dégradation, les deux dernières n'ont plus lieu d'être. Nous avons donc supprimé ces séquences et fait en sorte d'égaliser celles qui restent. En entraînant le modèle avec les nouvelles données nous avons réussi à améliorer les résultats. Cependant ils restent inférieur aux résultats du premier CNN. Les résultats indiquent une précision de 88% et une perte de 0,4. Bien que ces résultats soient encourageants, des améliorations demeurent nécessaires.




Figure 5: Evaluation de l'accuracy au cours des epoch pour le nouveau CNN multiclasse




Figure 6: Evaluation de la loss au cours des epoch pour le nouveau CNN multiclasse

L'étape suivante consiste à perfectionner ce modèle pour obtenir des performances équivalentes, voire



supérieures, à celles du modèle initial. Malgré ces défis, notre approche représente une avancée significative dans la détection de dégradations de structures routières par le biais de l'apprentissage profond.

## 4.2 Localisation GPS des détériorations

### 4.2.1 Liaison entre les Dégradations Détectées et les Données GPS

Cette approche de fenêtre glissante nous permet de localiser précisément les instants dans lesquels des dégradations ont été détectées. Les indices de ces détections sont stockés dans la liste `all_predicted_indices`.

Par la suite, nous avons associé ces indices aux données GPS recueillies simultanément avec les données accélérométriques. Chaque indice correspond à un enregistrement au même moment, reliant ainsi les détections de dégradations aux coordonnées géographiques respectives.

Pour visualiser ces emplacements sur une carte, nous avons utilisé la bibliothèque Folium [3]. Les coordonnées GPS associées aux indices détectés ont été enregistrées dans un fichier CSV (`detected_gps_data.csv`). Les premières entrées de ce fichier ont été modifiées à des fins de test, en utilisant les coordonnées de la ville d'Illkirch [1]:

```
# Extraire les données GPS correspondant aux indices détectés
detected_gps_data = gps_data.iloc[all_predicted_indices]

# Modification arbitraire des coordonnées pour les deux points (index 0 et 1) (POUR TESTER. Coordonnées de Illkirch)
detected_gps_data.loc[detected_gps_data.index[0], 'latitude'] = 48.5298611
detected_gps_data.loc[detected_gps_data.index[0], 'longitude'] = 7.7116218

detected_gps_data.loc[detected_gps_data.index[1], 'latitude'] = 48.52127758935057
detected_gps_data.loc[detected_gps_data.index[1], 'longitude'] = 7.704068699414068
```

Figure 7: Modification arbitraire des données GPS (test)

Enfin, une carte interactive a été générée, centrée sur le premier point GPS associé à une détection. Des marqueurs ont été ajoutés à chaque position GPS détectée, offrant ainsi une représentation visuelle des endroits où les dégradations ont été identifiées.

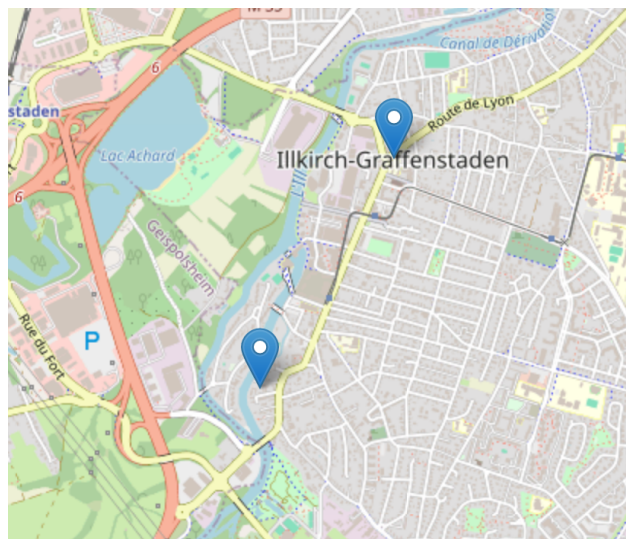


Figure 8: Visualisation des données GPS arbitraires sur la carte

L'objectif prochain est d'établir un moyen interactif de visualisation de cette carte.

## 5 Conclusion

L'analyse des données a révélé des comportements significatifs, en particulier lors de la traversée de dos d'âne. L'établissement d'une preuve de concept nous a permis de confirmer la validité des données augmentées.

Le modèle initial de fenêtre glissante a été amélioré par l'introduction d'un modèle de classification binaire. Cependant, l'application du modèle de prédiction de classes sur les séquences découpées a révélé des défis, conduisant à la création d'un nouveau modèle multiclasse. Bien que des améliorations soient nécessaires, ces résultats sont prometteurs.

La liaison entre les indices de détection et les données GPS offre la possibilité de visualiser géographiquement les endroits où les dégradations ont été identifiées. La création d'une carte interactive facilite ainsi la prise de décision pour l'entretien des routes.

## Bibliographie

- [1] Coordonnées gps. <https://www.coordonnees-gps.fr>. Accessed: 2023.
- [2] Team Asana. Comment faire un proof of concept (poc)? 4 étapes et des outils pratiques. <https://asana.com/fr/resources/proof-of-concept>. Accessed: 2023.
- [3] DataScientest. Folium : Découvrez la bibliothèque python open source. <https://datascientest.com/folium-tout-savoir>. Accessed: 2023.
- [4] Clement Chatelaint Romain Herault. Initiez-vous au deep learning. <https://openclassrooms.com/fr/courses/5801891-initiez-vous-au-deep-learning/5814641-initiez-vous-aux-problematiques-liees-au-traitement-de-sequences>. Accessed: 2023.